

DailyBox 마케팅 전략 분석 리포트

29 기 백승엽

Part 1. 고객 이해 (EDA)

1) 데이터 개요

고객 6,000명, 13개 변수, 결측치 없음 / 나이는 18~78세(평균 40.3세)로 폭넓게 분포하며, 월 구매액(monthly_spend)은 평균 32.3, 표준편차 16.9, 최소 8.26 ~ 최대 288.44로 편차가 큼니다.

2) 매출 분포와 로그변환




그림 1. monthly_spend 원본 분포(좌) vs log1p 변환 후 분포(우)

monthly_spend의 왜도는 **2.55**로 강한 우측 편포를 보입니다. 소수의 고가치 고객이 매우 큰 금액을 지출하며 분포의 꼬리를 길게 만들고 있습니다. log1p 변환 후 왜도는 **0.38**로 크게 줄어 대칭적인 분포가 되며, 이는 이후 정규성을 가정하는 분석(회귀 등)에 더 적합한 형태입니다.

3) 채널·등급별 매출




그림 2. 유입 채널별(좌), 멤버십 등급별(우) 월 매출 Boxplot

채널별 평균 매출은 **Influencer(42.9) > Referral(36.7) > Organic Search(30.5) > Social Ads(25.9)** 순이며, 등급별로는 **Gold(36.5) > Silver(32.9) > Basic(30.9)** 순입니다. Influencer 채널과 Gold 등급 고객이 상대적으로 고가치 고객군으로 관찰됩니다.

Part 2. 가정 확인

4) 1 종/2 종 오류

H0: "쿠폰 캠페인은 매출에 효과가 없다." **1종 오류**(실제로 효과가 없는데 있다고 잘못 판단)는 효과가 없는 캠페인에 예산을 계속 투입하는 **예산 낭비**로 이어집니다. **2종 오류**(실제로 효과가 있는데 없다고 잘못 판단)는 매출을 늘릴 수 있는 캠페인을 중단시켜 **매출 성장 기회를 놓치는 기회 손실**로 이어집니다.

5) 정규성 검정 (Shapiro-Wilk, Organic Search 채널)




그림 3. Organic Search 채널 monthly_spend Q-Q plot: 원본(좌) vs log1p(우)

H0: monthly_spend는 정규분포를 따른다 / H1: monthly_spend는 정규분포를 따르지 않는다 (유의수준 0.05 기준).

유의수준 0.05에서 원본 monthly_spend의 Shapiro-Wilk 검정 p-value는 약 3.63×10^{-21} 로, 귀무가설을 기각하였다. 따라서 원본 데이터는 정규분포를 따른다고 보기 어렵다. log1p 변환 후 p-value는 약 0.000245로 여전히 0.05보다 작아 정규성은 충족하지 못하였다. 그러나 Shapiro-Wilk 통계량이 약 0.8535에서 0.9873으로 증가하고 Q-Q plot의 점들이 기준 직선에 가까워졌으므로, 로그 변환을 통해 데이터의 정규성이 상당히 개선되었다고 해석할 수 있다.

6) 등분산성 검정 (Levene)

4개 채널 간 Levene 검정 결과 $p = 4.34 \times 10^{-44}$ 로 유의수준 0.05보다 작았다. 채널별 매출 변동성이 서로 다르므로, 이어지는 One-way ANOVA 해석 시 이 점을 한계로 고려해야 합니다.

Part 3. 집단 비교 검정

7) 쿠폰 캠페인 효과 — Welch's t-test

구분	control (미발송)	treatment (발송)
표본 수	2,977	3,023
평균 매출	29.71	34.80

H_0 : Treatment 집단과 Control 집단의 평균 monthly_spend 는 같다.

H_1 : Treatment 집단과 Control 집단의 평균 monthly_spend 는 다르다.

Levene 검정 결과 p-value 가 약 1.16×10^{-19} 로 유의수준 0.05 보다 작아 등분산 가정이 충족되지 않았으며, 이에 따라 Welch's t-test 를 실시하였다. 검정 결과 $t = -11.88$, $p = 3.86 \times 10^{-32}$ 로 귀무가설을 기각하였다. Treatment 집단의 평균 지출액은 34.80 으로 Control 집단의 29.71 보다 약 5.10, 즉 약 17.2% 높았다. 따라서 쿠폰 캠페인이 고객의 월평균 지출액을 유의하게 증가시킨 것으로 판단되며, 비용 대비 효과가 적절하다는 전제에서 다음 분기에도 캠페인을 지속하는 것이 타당하다.

8) 채널 비교 — One-way ANOVA + Tukey HSD

H_0 는 4 개 유입 채널의 평균 monthly_spend 가 모두 같다는 것이고, H_1 은 적어도 한 채널의 평균이 다르다는 것이다. One-way ANOVA 결과 $F = 276.85$, $p = 2.67 \times 10^{-168}$ 로 유의수준 0.05 보다 작아 귀무가설을 기각하였다. 따라서 유입 채널별 평균 월 지출액에는 통계적으로 유의한 차이가 있다. Tukey HSD 사후검정 결과 모든 채널 쌍에서 유의한 차이가 확인되었으며, 평균 지출액은 Influencer, Referral, Organic Search, Social Ads 순으로 높았다. 따라서 Influencer 채널이 상대적으로 고가치 고객을 가장 많이 유입시키고, Social Ads 채널은 상대적으로 저가치 고객을 유입시키는 것으로 해석할 수 있다.

9) 교호작용 — Two-way ANOVA

Two-way ANOVA 결과, 유입 채널의 주효과는 $F = 284.97$, $p = 6.34 \times 10^{-173}$, 캠페인 그룹의 주효과는 $F = 159.79$, $p = 3.63 \times 10^{-36}$ 으로 모두 통계적으로 유의하였다. 또한 채널과 캠페인의 교호작용도 $F = 9.29$, $p = 3.97 \times 10^{-6}$ 으로 유의하였다. 따라서 고객의 월평균 지출액은 유입 채널과 쿠폰 발송 여부에 따라 달라지며, 쿠폰 캠페인의 효과 크기 역시 유입 채널마다 다르다고 해석할 수 있다.

Part 4. 회귀분석

10) 단순/다중회귀

모형	R ²	Adj. R ²	유의 변수(전부 p<0.001)
단순 (monthly_visits만)	0.054	0.054	monthly_visits (+0.927)
다중 (5개 변수)	0.218	0.217	monthly_visits(+0.92), avg_discount_rate(+11.4), online_ad_cost(+0.37), 채널, 성별

단순회귀에서 monthly_visits의 회귀계수는 0.927로, 방문 횟수가 1회 증가할 때 월 지출액이 평균 약 0.93 증가하는 양의 관계가 나타났다. 그러나 설명력은 $R^2 = 0.054$ 로 낮아 방문 횟수만으로는 월 지출액의 약 5.4%만 설명할 수 있었다. 다중회귀에서는 $R^2 = 0.218$, Adjusted $R^2 = 0.217$ 로 설명력이 크게 개선되었으나, 여전히 지출액 변동의 약 21.8%만 설명하므로 모형에 포함되지 않은 다른 요인도 존재한다고 볼 수 있다.

다른 변수를 통제한 상태에서 monthly_visits와 online_ad_cost는 월 지출액과 유의한 양의 관계를 보여, 방문 활성화와 광고 투자가 잠재적인 매출 전략으로 판단된다. avg_discount_rate 역시 유의한 양의 관계를 보였지만, 고지출 고객에게 더 높은 할인이 제공되었을 가능성과 할인 비용을 고려해야 하므로 ‘할인 확대가 매출을 증가시킨다’고 인과적으로 단정하기는 어렵다. 또한 Organic Search, Referral, Social Ads의 계수가 모두 기준 채널인 Influencer보다 음수로 나타나, Influencer 유입 고객의 지출액이 가장 높은 기존 채널 비교 결과와 일관된다.

11) 다중공선성 / VIF

변수 조합	online_ad_cost	offline_ad_cost	total_ad_cost
online+offline+total 모두 포함	inf	inf	inf
total 제외	1.0003	1.0002	(제외)

total_ad_cost = online_ad_cost + offline_ad_cost로 정의되어 세 광고비 변수 사이에 완전한 선형결합 관계가 존재한다. 따라서 세 변수를 동시에 포함하면 각 변수를 나머지 변수로 완벽하게 설명할 수 있어 $R^2 = 1$ 이 되고, VIF의 분모인 $1 - R^2$ 가 0이 되어 VIF가 무한대(inf)로 나타난다. 이는 완전 다중공선성으로 인해 각 광고비 변수의 개별 회귀계수를 안정적으로 구분하기 어렵다는 의미이다. total_ad_cost를 제외한 결과 online_ad_cost와 offline_ad_cost의 VIF가 각각 약 1.0003과 1.0002로 낮아져 다중공선성 문제가 해소되었다. 따라서 온라인·오프라인 광고비의 개별 효과를 분석할 경우 total_ad_cost를 제외하는 것이 적절하다.

12) 잔차 진단




그림 4. 다중회귀 모형 잔차 진단 — 원본(위) vs $\log 1p$ 변환 모형(아래)

원본 모형의 잔차는 Q-Q plot에서 기준 직선을 크게 벗어났으며, Shapiro-Wilk 검정 결과도 $p \approx 4.3 \times 10^{-20}$ 으로 나타나 정규성 가정이 충족되지 않았다. 또한 잔차와 예측값 산점도에서 예측값이 증가할수록 잔차의 퍼짐이 커지는 부채꼴 형태가 관찰되어 등분산성에도 문제가 있는 것으로 판단된다. 반면 종속변수를 $\log 1p(\text{monthly_spend})$ 로 변환한 모형에서는 Shapiro-Wilk 통계량이 약 0.87에서 0.99로 증가하고, Q-Q plot이 기준 직선에 가까워졌으며 잔차의 부채꼴 형태도 크게 완화되었다. 따라서 로그 변환 후 잔차의 정규성과 등분산성이 상당히 개선되었으므로 원본 모형보다 로그 변환 모형이 회귀 가정을 더 잘 만족하는 것으로 판단된다. 다만 두 모형은 종속변수의 척도가 다르므로 R^2 의 상승만으로 모형의 우수성을 직접 판단하기보다는 잔차 진단 결과를 중심으로 비교해야 한다.

Part 5. 타겟팅 (로지스틱 회귀)

13~14) 로지스틱 회귀 & 오즈비

변수	오즈비 (exp(coef))	해석
쿠폰 발송 (treatment)	2.43	쿠폰 받은 고객의 반응 오즈가 약 2.4배
멤버십 Gold (vs Basic)	2.02	Gold 등급 고객의 반응 오즈가 약 2배
멤버십 Silver (vs Basic)	1.41	Silver 등급 고객의 반응 오즈가 약 1.4배
채널 Organic/Referral/Social (vs Influencer)	0.52 ~ 0.59	Influencer 대비 반응 오즈 낮음
age	1.0125	1세 증가 시 반응 오즈 약 1.25% 증가
monthly_visits	1.041	1회 방문 증가 시 반응 오즈 약 4.1% 증가

로지스틱 회귀 결과, 모든 설명변수는 $p < 0.001$ 수준에서 통계적으로 유의하였다. 다른 변수를 통제했을 때 쿠폰을 발송한 Treatment 집단의 반응 오즈는 Control 집단의 약 2.43배였다. 또한 Gold와 Silver 고객의 반응 오즈는 Basic 고객보다 각각 약 2.02배와 1.41배 높았으며, Organic Search, Referral, Social Ads 유입 고객의 반응 오즈는 기준 채널인 Influencer보다 낮게 나타났다. 나이가 1세 증가할 때 반응 오즈는 약 1.3%, 월 방문 횟수가 1회 증가할 때는 약 4.1% 증가하였다. 따라서 다음 캠페인에서는 기본 반응 가능성이 높은 Influencer 유입 고객과 Gold·Silver 등급 고객을 우선 타겟으로 고려하고, 이들에게 쿠폰을 발송하는 전략이 적절하다.

종합 결론

1. 캠페인 지속 여부

캠페인 지속을 권장합니다. Welch's t-test 결과 쿠폰 발송군의 월평균 지출액이 미발송군보다 유의하게 높았으며($p \approx 3.9 \times 10^{-32}$), 로지스틱 회귀에서도 쿠폰 발송 고객의 반응 오즈가 미발송 고객의 약 2.43 배로 나타났습니다. 따라서 쿠폰 캠페인은 지출액과 반응 가능성 모두에서 긍정적인 효과를 보였습니다. 다만 향후에는 쿠폰 비용을 포함한 순이익과 ROI를 함께 점검해야 합니다.

2. 채널 예산 배분

채널별 평균 지출액은 **Influencer > Referral > Organic Search > Social Ads** 순으로 나타났으며, 모든 채널 쌍에서 유의한 차이가 확인되었습니다. 따라서 Influencer 채널의 예산 비중을 우선 확대하고, 성과가 가장 낮은 Social Ads는 예산 일부를 축소하거나 소재·타겟을 재검토하는 것이 적절합니다. 다만 채널별 고객 획득비용과 실제 ROI가 제공되지 않았으므로, 전면적인 예산 변경보다는 단계적인 재배분과 성과 검증을 권장합니다. 또한 채널과 캠페인의 교호작용이 유의했으므로 채널별 쿠폰 효과를 지속해서 모니터링해야 합니다.

3. 매출 레버

다중회귀 분석에서 monthly_visits, avg_discount_rate, online_ad_cost는 모두 월 지출액과 유의한 양의 관계를 보였습니다. 이 중 monthly_visits는 해석이 명확하고 실행 가능성이 높으므로 알림, 리마인드, 재방문 혜택 및 리텐션 프로그램 등 **고객의 재방문을 유도하는 전략에 우선 투자**하는 것이 적절합니다. 광고비 역시 지출액과 양의 관계가 있었지만 비용 대비 추가 매출을 확인해야 하며, 할인율은 역인과관계와 할인 비용의 가능성이 있어 단순한 할인 확대 전략은 신중하게 적용해야 합니다.

4. 타게팅

로지스틱 회귀 결과 쿠폰 발송 여부가 가장 큰 오즈비를 보인 핵심 변수였으며, Gold와 Silver 고객은 Basic 고객보다 반응 오즈가 각각 약 2.02배와 1.41배 높았습니다. 또한 Influencer 유입 고객은 다른 채널의 고객보다 기본 반응 가능성이 높게 나타났습니다. 따라서 다음 캠페인에서는 **Influencer 유입 고객과 Gold 등급 고객을 최우선 타겟으로 설정하고, Silver 고객을 차순위로 고려하는 전략**을 제안합니다.

5. 분석의 한계

본 데이터는 한 달간의 스냅샷이므로 계절성과 장기 추세를 반영하지 못합니다. total_ad_cost는 online_ad_cost와 offline_ad_cost의 합으로 정의되어 세 변수를 함께 사용하면 완전 다중공선성이 발생하므로 분석 목적에 따라 중복 변수를 제외해야 합니다. 또한 다중회귀 모형의 설명력은 약 21.8%, 로지스틱 회귀의 의사결정 설명력도 제한적이므로 분석에 포함되지 않은 다른 고객 특성이 존재할 수 있습니다. 쿠폰 발송은 무작위 배정이므로 비교적 인과적으로 해석할 수 있지만, 채널·멤버십·할인율·방문 횟수 등 관측 변수와 성과의 관계는 인과관계로 단정할 수 없습니다.